

Clasificación Automática de Ambientes Inmobiliarios en el Perú

Comparando embeddings visuales CLIP, DINOv2, Place365

Víctor Gabriel Peralta

Facultad de Ingeniería, Universidad de Buenos Aires (FIUBA)

15 de junio de 2026

Índice

- 1 Introducción
- 2 Metodología
- 3 Resultados
- 4 Demo
- 5 Conclusiones

Contexto del Problema


- Las plataformas inmobiliarias latinoamericanas manejan millones de anuncios
- Imágenes de propiedades subidas sin etiquetas o con metadatos inconsistentes
- Algunas publicaciones muestran habitaciones vacías o recién habilitadas, donde el uso del espacio no siempre es evidente
- La clasificación manual es costosa y propensa a errores
- Perú: espacios multifuncionales, estilos arquitectónicos variados, anuncios informales

Reto: *Cómo llevar la experiencia de fotos categorizadas de Airbnb a portales inmobiliarios peruanos.*

Objetivo: clasificar automáticamente 17 categorías de ambientes a partir de imágenes de Urbania.pe, Airbnb y MIT Indoor Scenes.


Motivación: Airbnb vs Urbania.pe

Airbnb — Con clasificación



Fotos etiquetadas automáticamente:
Sala · Cocina · Habitación · Baño

Urbania.pe — Sin clasificación



Solo carrusel de fotos:
Sin etiquetas · Sin categorización · Caótico

Oportunidad: convertir carruseles sin estructura en recorridos fotográficos categorizados.

Qué aporta este trabajo

- ① Dataset y pipeline reproducible desde Urbania.pe: scraping, auto-etiquetado y curación manual
- ② Comparación sistemática: CLIP zero-shot vs embeddings CLIP/DINOv2/Place365 + clasificadores ML
- ③ Diseño experimental con split antes del aumento para evitar fuga de datos
- ④ Prototipo Streamlit con tres modos de uso para llevar el modelo a una demo operativa

Indoor Real Estate Room Classifier

Arquitectura del pipeline: scraping → etiquetado → preprocesamiento → embeddings → clasificación → app Streamlit



17 clases

sala · cocina · dormitorio · baño · comedor · lavandería · balcón · terraza · gimnasio
exterior · oficina · jardín · parking · pasadizo · recepción · walking closet · piscina

Extracción de Características: Del Baseline a Foundation Models

Baseline: Place365 ResNet50

(MIT CSAIL)

- Pre-entrenado en MIT Indoor Scenes (365 categorías)
- 1.8M imágenes de escenas indoor/outdoor
- CNN (no transformer), 2048 dimensiones

Ref.: Zhou et al., *Places: A 10 Million Image Database for Scene Recognition*, TPAMI 2017.

CLIP ViT-B/32 (OpenAI)

- Imágenes + texto → espacio compartido
- 512 dimensiones, alineado con lenguaje
- Entrenado en WIT (400M pares)

DINOv2 ViT-B/14 (Meta)

- Auto-supervisado en LVD-142M
- 768 dimensiones, sin lenguaje

Embeddings extraídos

Backbone	Dim	Total
CLIP ViT-B/32	512	16,012
DINOv2 ViT-B/14	768	16,012
Place365 ResNet50	2048	16,012

14,492 train + 1,520 test

L2-normalizados y cacheados a disco

Clasificadores:

- SVM RBF (mejor para CLIP y DINOv2)
- XGBoost (mejor para Place365)

Preprocesamiento: Comparación Justa entre Backbones

Antes de comparar CLIP, DINOv2 y Place365, cada imagen debe entrar al modelo como ese modelo espera verla.

Modelo	Dataset base	Fuente del preproc.	Res.	Norm.
CLIP	WIT (400M pares)	CLIPProcessor oficial	224×224	Stats WIT
DINOv2	LVD-142M	AutoImageProcessor oficial	224×224	ImageNet
Place365	MIT Indoor Scenes	Receta Places365/torchvision	224×224	ImageNet

Misma imagen, tres entradas

- CLIP usa su *processor* oficial
- DINOv2 usa su *AutoImageProcessor*
- Place365 sigue la receta de escenas indoor

Salida comparable

- Todas producen tensor (1, 3, 224, 224)
- Se extraen embeddings para train y test
- 16,012 embeddings por backbone

Aumento de Datos: Más Datos sin Engañar al Test

El problema Algunas clases tenían pocas imágenes y alta variabilidad visual: balcones, terrazas, pasadizos o *walking closets*.

El riesgo Si se aumenta antes de separar train/test, una versión casi duplicada de una imagen puede aparecer en ambos conjuntos.

Decisión experimental: primero split, después aumento solo en train.

- Test intacto: 1,520 imágenes reales, sin transformaciones
- Train balanceado hasta 700 imágenes por clase
- Objetivo: robustez en clases minoritarias, no inflar la métrica

La mejora buscada no era crear imágenes nuevas, sino enseñar invariancias que aparecen en anuncios inmobiliarios reales.

Transformaciones realistas

Transformación	Intención
Crop leve	Encuadres distintos
Flip horizontal	Simetría de ambientes
Brillo/contraste	Condiciones de luz
Rotación $\pm 5^\circ$	Fotos torcidas
Perspectiva suave	Toma desde celular
Blur/JPEG	Calidad de anuncio

Lo que se evitó

- Rotaciones $90^\circ/180^\circ$ y vertical flip
- Recortes extremos, MixUp y CutMix
- Cambios de color agresivos

Comparación de Modelos


Backbone	Dataset	Acc.	F1	Prec.	Rec.
CLIP + SVM	WIT	89.0%	89.0%	89.1%	89.0%
DINOv2 + SVM	LVD-142M	88.3%	88.4%	88.7%	88.3%
Place365 + XGB	MIT Indoor	86.2%	86.2%	86.4%	86.2%
CLIP Zero-shot	WIT	72.2%	75.2%	84.9%	72.2%

Test: 1,520 imágenes, 17 clases · 16,012 embeddings por backbone (14,492 train + 1,520 test)

CLIP Zero-shot vs CLIP + SVM Classifier

CLIP Zero-shot


Modelo CLIP por defecto, sin entrenamiento supervisado



Predice como **Walking Closet**

CLIP + SVM Classifier

Embeddings CLIP congelados + SVM RBF entrenado



Predice como **Dormitorio**

Mismo backbone visual (CLIP), pero el SVM aprende la frontera entre las 17 clases del dominio inmobiliario: +13.8 puntos F1 frente al zero-shot.

- ① **CLIP** $\approx$ **DINOv2** $>$ **Place365** – 89.0% vs 88.4% vs 86.2% F1
- ② **SVM RBF** convierte embeddings congelados en un clasificador competitivo
- ③ **CLIP zero-shot** es una base razonable, pero queda 14 puntos F1 por debajo del SVM
- ④ **Aumento de datos** mejora +3.1% F1 cuando se aplica solo al train

Lectura principal: no hace falta fine-tunear un modelo grande; extraer buenas representaciones y entrenar un clasificador liviano alcanza 89.0% F1.

Rendimiento por Clase: Dónde el Modelo es Confiable

El 89.0% global no se distribuye igual: algunas clases son visualmente claras y otras viven en zonas grises.

Muy confiables

$F1 \geq 0.93$

- Gimnasio: **1.000**
- Baño: **0.949**
- Cocina: **0.945**
- Piscina: **0.932**

Rasgos visuales distintivos:
equipamiento, superficies y objetos
específicos.

Robustas, pero variables

$F1 \approx 0.89-0.90$

- Sala: **0.901**
- Dormitorio: **0.897**
- Walking Closet: **0.889**
- Pasadizo: **0.889**

Funcionan bien, aunque cambian mucho
por estilo, encuadre y tamaño del
ambiente.

Zonas grises

$F1 < 0.77$

- Terraza: **0.763**
- Balcón: **0.750**
- Patio/Jardín: **0.722**
- Área de trabajo: **0.667**

Comparten objetos, luz y distribución
espacial con exterior, sala u oficina.

F1 por Clase y Modelo


Clase	CLIP	DINO	Place	Mejor
gimnasio	1.000	1.000	0.962	empate
baño	0.949	0.933	0.898	CLIP
cocina	0.945	0.924	0.931	CLIP
piscina	0.932	0.913	0.902	CLIP
dormitorio	0.897	0.923	0.884	DINO
sala	0.901	0.892	0.888	CLIP
walking closet	0.889	0.919	0.850	DINO
pasadizo	0.889	0.910	0.865	DINO
exterior	0.873	0.865	0.817	CLIP

Clase	CLIP	DINO	Place	Mejor
comedor	0.866	0.845	0.844	CLIP
lavandería	0.857	0.857	0.870	Place
estacionamiento	0.833	0.917	0.889	DINO
recepción	0.815	0.880	0.667	DINO
terraza	0.763	0.636	0.658	CLIP
balcón	0.750	0.764	0.727	DINO
patio/jardín	0.722	0.709	0.624	CLIP
área trabajo	0.667	0.606	0.429	CLIP
Victorias	10	6	1	

CLIP gana en 10/17 clases; DINOv2 destaca en clases estrechas o con bajo soporte; Place365 solo gana en lavandería.

Del mejor modelo a una demo navegable

- Subida de imágenes de una propiedad
- Agrupación automática por ambiente
- Comparación entre zero-shot, clasificador ML y modo avanzado
- Mejora extra: detección YOLO11n de muebles/objetos indoor con datasets Roboflow
- Salida pensada para ordenar carruseles inmobiliarios



Mockup de la aplicación web: carga de imágenes, resumen y clasificación por ambiente.

- ① **CLIP + SVM RBF = 89.0% F1** en 17 clases, con el mejor balance general.
- ② **Embeddings congelados + SVM** ofrecen buen rendimiento sin fine-tuning pesado.
- ③ **Split antes del aumento** fue clave para prevenir fuga de datos.
- ④ **CLIP gana en 10/17 clases**; DINOv2 complementa en clases estrechas o con bajo soporte.

- Clasificación multi-etiqueta para ambientes integrados
- Calibración de confianza y optimización de umbrales
- Despliegue API REST en producción

¡Gracias!

Víctor Gabriel Peralta
gabriel.peralta.12.1998@gmail.com
Facultad de Ingeniería, Universidad de Buenos Aires